

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística



ANÁLISIS DE COMPONENTES PRINCIPALES (ACP)

OBJETIVO

Comprobar la utilidad de las técnicas multivariantes exploratorias de reducción de la dimensión (ACP) para visualizar y descubrir fenómenos latentes en una matriz de datos

CASO 1 ASIGNATURAS (Ejemplo inicial de teoría)

1. Importe el archivo de datos de extensión xlsx.

A screenshot of the RStudio interface. The 'Environment' pane shows a data frame named 'Ejemplo_Ciencias_Letras'. The data frame is displayed in a table view with 15 rows and 8 columns. The columns are: 'Alumno', 'Lengua', 'Matemáticas', 'Física', 'Filosofía', 'Historia', 'Química', and 'Educación física'. The rows are numbered 1 to 15, corresponding to the students listed in the 'Alumno' column.

	Alumno	Lengua	Matemáticas	Física	Filosofía	Historia	Química	Educación física
1	Ana	5	5	5	5	5	5	5
2	Juan	7	4	3	4	7	3	8
3	Manuel	5	8	7	5	6	7	5
4	Sara	7	2	4	7	7	3	6
5	Paloma	8	9	10	8	7	9	4
6	Víctor	4	9	8	3	4	7	5
7	Jorge	6	4	4	5	5	3	7
8	Susana	4	7	8	3	2	8	3
9	María	5	5	4	6	5	5	1
10	Javier	7	4	5	8	8	4	6
11	Mónica	7	8	8	7	6	7	9
12	Lucía	4	3	3	3	2	1	4
13	Pablo	7	4	4	8	7	4	5
14	Tomás	3	5	5	3	3	5	7
15	Pilar	5	6	6	5	5	6	6

Comprobemos que la importación se ha realizado correctamente:

```
class(Ejemplo_Ciencias_Letras); dim(Ejemplo_Ciencias_Letras)
```

```
head(Ejemplo_Ciencias_Letras)
```

```
datos<-as.data.frame(Ejemplo_Ciencias_Letras)
```

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

Almacenaremos los datos en un objeto de tipo matriz, que contenga las variables cuantitativas a analizar,

```
row.names(datos)<-datos[,1]
```

```
datos<-datos[,-1]
```

```
head(datos)
```

```
Datos.ord<-datos[,c(1,5,7,4,2,3,6)]
```

2. Calcule la matriz de correlaciones R y represéntela gráficamente.

```
library(corrplot)
```

```
corrplot(cor(Datos.ord), tl.col="black", tl.srt=45, tl.cex=1)
```



3. Centre la matriz de datos y almacene la nueva matriz en un objeto denominado *datos.center*

Primera opción:

```
n<-dim(Datos.ord)[1]
```

```
I<-diag(1, nrow=n) #Matriz identidad
```

```
J<-matrix(1, nrow = n, ncol=n) #Matriz unidad
```

```
dt.center2 <- (I-(1/n)*J)%*%as.matrix(Datos.ord)
```

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

```
> round(dt.center2, 3)
```

	Lengua	Historia	Educación física	Filosofía	Matemáticas	Física	Química
[1,]	-0.6	-0.267	-0.4	-0.333	-0.533	-0.6	-0.133
[2,]	1.4	1.733	2.6	-1.333	-1.533	-2.6	-2.133
[3,]	-0.6	0.733	-0.4	-0.333	2.467	1.4	1.867
[4,]	1.4	1.733	0.6	1.667	-3.533	-1.6	-2.133
[5,]	2.4	1.733	-1.4	2.667	3.467	4.4	3.867
[6,]	-1.6	-1.267	-0.4	-2.333	3.467	2.4	1.867
[7,]	0.4	-0.267	1.6	-0.333	-1.533	-1.6	-2.133
[8,]	-1.6	-3.267	-2.4	-2.333	1.467	2.4	2.867
[9,]	-0.6	-0.267	-4.4	0.667	-0.533	-1.6	-0.133
[10,]	1.4	2.733	0.6	2.667	-1.533	-0.6	-1.133
[11,]	1.4	0.733	3.6	1.667	2.467	2.4	1.867
[12,]	-1.6	-3.267	-1.4	-2.333	-2.533	-2.6	-4.133
[13,]	1.4	1.733	-0.4	2.667	-1.533	-1.6	-1.133
[14,]	-2.6	-2.267	1.6	-2.333	-0.533	-0.6	-0.133
[15,]	-0.6	-0.267	0.6	-0.333	0.467	0.4	0.867

```
colMeans(Datos.ord) #Vector de medias
```

```
> colMeans(Datos.ord)
```

Lengua	Historia	Educación física	Filosofía	Matemáticas	Física	Química
5.600000	5.266667	5.400000	5.333333	5.533333	5.600000	5.133333

Segunda opción:

```
dt.center<-scale(Datos.ord, scale = F, center=T)
```

```
> round(dt.center, 3)
```

	Lengua	Historia	Educación física	Filosofía	Matemáticas	Física	Química
Ana	-0.6	-0.267	-0.4	-0.333	-0.533	-0.6	-0.133
Juan	1.4	1.733	2.6	-1.333	-1.533	-2.6	-2.133
Manuel	-0.6	0.733	-0.4	-0.333	2.467	1.4	1.867
Sara	1.4	1.733	0.6	1.667	-3.533	-1.6	-2.133
Paloma	2.4	1.733	-1.4	2.667	3.467	4.4	3.867
Víctor	-1.6	-1.267	-0.4	-2.333	3.467	2.4	1.867
Jorge	0.4	-0.267	1.6	-0.333	-1.533	-1.6	-2.133
Susana	-1.6	-3.267	-2.4	-2.333	1.467	2.4	2.867
María	-0.6	-0.267	-4.4	0.667	-0.533	-1.6	-0.133
Javier	1.4	2.733	0.6	2.667	-1.533	-0.6	-1.133
Mónica	1.4	0.733	3.6	1.667	2.467	2.4	1.867
Lucía	-1.6	-3.267	-1.4	-2.333	-2.533	-2.6	-4.133
Pablo	1.4	1.733	-0.4	2.667	-1.533	-1.6	-1.133
Tomás	-2.6	-2.267	1.6	-2.333	-0.533	-0.6	-0.133
Pilar	-0.6	-0.267	0.6	-0.333	0.467	0.4	0.867

Lengua	Historia	Educación física	Filosofía	Matemáticas	Física	Química
5.600000	5.266667	5.400000	5.333333	5.533333	5.600000	5.133333

¡SON LA MISMA!

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

4. Calcule la Descomposición Espectral de la matriz de covarianzas de *datos.center* y la Descomposición en Valores Singulares de los datos centrados *datos.center*. ¿Qué relación observa entre los resultados?

```
res.svd<-svd(dt.center) #Descomposición en valores singulares  $X=UDV^T$ 
```

```
res.svd$d #Valores singulares
```

```
res.svd$V #vectores singulares derecha V
```

```
> res.svd$V #vectores singulares derecha
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]
[1,]  0.01883405 -0.47670169 -0.04102837 -0.049317628 -0.6719891  0.38498902 -0.41048666
[2,]  0.04053134 -0.59984199 -0.03698548  0.624927208  0.2045740  0.14540121  0.42854736
[3,]  0.09456495 -0.24630780  0.93345062 -0.168571836  0.1457310 -0.05923475 -0.07679276
[4,] -0.01264712 -0.58739866 -0.31846961 -0.460008667  0.2496839 -0.51424932 -0.12238307
[5,] -0.57649610  0.02616306  0.13511969  0.436890723 -0.2839741 -0.58001521 -0.20193556
[6,] -0.56223299 -0.06686240  0.06482297 -0.419676043 -0.2477799  0.15192210  0.64390859
[7,] -0.58347778 -0.04566490 -0.04167075 -0.002798731  0.5300607  0.45075810 -0.41421839
```

```
cov(dt.center) #Matriz de covarianzas  $S=V\Lambda V^T$ 
```

```
res.eigen<-eigen(cov(dt.center)) #Descomposición espectral
```

```
valpropiosL<-res.eigen$values #Valores propios
```

```
vectpropiosV<-res.eigen$vectors #Vectores propios
```

```
> V
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]
[1,] -0.01883405 -0.47670169  0.04102837  0.049317628  0.6719891  0.38498902 -0.41048666
[2,] -0.04053134 -0.59984199  0.03698548 -0.624927208 -0.2045740  0.14540121  0.42854736
[3,] -0.09456495 -0.24630780 -0.93345062  0.168571836 -0.1457310 -0.05923475 -0.07679276
[4,]  0.01264712 -0.58739866  0.31846961  0.460008667 -0.2496839 -0.51424932 -0.12238307
[5,]  0.57649610  0.02616306 -0.13511969 -0.436890723  0.2839741 -0.58001521 -0.20193556
[6,]  0.56223299 -0.06686240 -0.06482297  0.419676043  0.2477799  0.15192210  0.64390859
[7,]  0.58347778 -0.04566490  0.04167075  0.002798731 -0.5300607  0.45075810 -0.41421839
```

5. Implemente el Análisis de Componentes Principales a partir de la descomposición espectral siguiendo la teoría.

```
cargasV<-res.eigen$vectors #Loadings o cargas (V)
```

```
row.names(cargasV)<-colnames(dt.center)
```

```
colnames(cargasV)<-c("CP1","CP2","CP3","CP4","CP5","CP6","CP7")
```

```
> round(cargasV,3)
      CP1    CP2    CP3    CP4    CP5    CP6    CP7
Lengua   -0.019 -0.477  0.041  0.049  0.672  0.385 -0.410
Historia -0.041 -0.600  0.037 -0.625 -0.205  0.145  0.429
Educación física -0.095 -0.246 -0.933  0.169 -0.146 -0.059 -0.077
Filosofía  0.013 -0.587  0.318  0.460 -0.250 -0.514 -0.122
Matemáticas  0.576  0.026 -0.135 -0.437  0.284 -0.580 -0.202
Física    0.562 -0.067 -0.065  0.420  0.248  0.152  0.644
Química    0.583 -0.046  0.042  0.003 -0.530  0.451 -0.414
```

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

```
puntY<-dt.center%*%cargasV #Scores o puntuaciones factoriales (Y=XV)
row.names(puntY)<-row.names(dt.center)
colnames(puntY)<-colnames(cargasV)
```

```
> round(puntY,3)
      CP1    CP2    CP3    CP4    CP5    CP6    CP7
Ana   -0.667  0.773  0.338 -0.103 -0.437  0.083 -0.020
Juan  -3.950 -1.333 -2.443 -1.616  0.591  0.855 -0.349
Manuel 3.313  0.026 -0.077 -1.194 -0.354 -0.306  0.262
Sara  -4.314 -2.722  0.585  0.720 -0.186  0.743  0.485
Paloma 6.779 -3.785  1.726  0.369  0.821  0.288  0.070
Víctor 4.527  2.837 -1.028 -0.930  0.415 -0.381  0.502
Jorge  -3.181 -0.065 -1.371  0.295  0.472 -0.123 -0.198
Susana 4.228  4.431  1.076  0.859  0.017  1.057 -0.211
María  -0.838  1.237  4.455 -0.737 -0.351 -0.346 -0.479
Javier -2.043 -3.969  0.647  0.104 -0.355 -0.183  0.617
Mónica 3.485 -3.154 -3.156  0.919  0.156 -0.649 -0.467
Lucía  -5.069  4.734  0.716  0.657  1.207 -0.597  0.199
Pablo  -2.470 -3.056  1.608  0.140 -0.252 -0.421 -0.379
Tomás  -0.763  3.608 -2.322  0.465 -1.163 -0.067  0.035
Pilar   0.961  0.440 -0.754  0.051 -0.581  0.047 -0.069
```

6. Implemente el Análisis de Componentes Principales a partir de la función *princomp*.

```
res.acp<-princomp(Datos.ord, cor=F) #Sobre la matriz de covarianzas
```

- Obtenga los valores propios y el % de varianza explicada por cada componente.

```
valores.propios<-res.acp$sdev^2 #Varianza explicada
```


```
porc<-valores.propios/sum(valores.propios)*100
```

```
porc.acum<-cumsum(porc)
```

```
data.frame(valores.propios,porc, porc.acum)
```

```
> data.frame(valores.propios,porc,porc.acum)
  valores.propios      porc porc.acum
Comp.1    12.6923262  49.2544565  49.25446
Comp.2     8.2662747  32.0785065  81.33296
Comp.3     3.5194412  13.6577141  94.99068
Comp.4     0.5641307   2.1891928  97.17987
Comp.5     0.3503449   1.3595655  98.53944
Comp.6     0.2574014   0.9988843  99.53832
Comp.7     0.1189699   0.4616803 100.00000
```

```
plot(res.acp, type="lines", ylim=c(0,14), main = "Gráfico de sedimentación")
```



ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

- ¿Cuántas componentes principales debemos retener? Ayúdese del scree-plot y del listado de valores propios.

Autovalores mayores a 1: **3**

Porcentaje de varianza del 75%: **2**

Gráfico de sedimentación: **2**

Decisión del investigador: **2**

- Analice la estructura de la matriz de cargas para las componentes extraídas:

```
cargas<-res.acp$loadings
```

```
round(cargas[,1:7],3)
```

	Comp.1	Comp.2
Lengua	0,019	0,477
Historia	0,041	0,600
Educación física	0,095	0,246
Filosofía	-0,013	0,587
Matemáticas	-0,576	-0,026
Física	-0,562	0,067
Química	-0,583	0,046

- Realice la representación gráfica de las puntuaciones de los estudiantes en el espacio de dimensión reducida, generado por tantas componentes principales como haya decidido retener.

```
scores<-res.acp$scores
```

```
round(res.acp$scores[,1:2],3)
```


```
> round(res.acp$scores[,1:2],3)
```

	Comp.1	Comp.2
Ana	0.667	-0.773
Juan	3.950	1.333
Manuel	-3.313	-0.026
Sara	4.314	2.722
Paloma	-6.779	3.785
Víctor	-4.527	-2.837
Jorge	3.181	0.065
Susana	-4.228	-4.431
María	0.838	-1.237
Javier	2.043	3.969
Mónica	-3.485	3.154
Lucía	5.069	-4.734
Pablo	2.470	3.056
Tomás	0.763	-3.608
Pilar	-0.961	-0.440

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

```
plot(res.acp$scores[,1:2], pch=18, xlab="Comp.1 (Ciencias)", ylab="Comp.2 (Letras)")  
text(res.acp$scores[,1:2]+0.2, label=row.names(Datos.ord), cex=1.25)
```





ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

CASO 2 PROPUESTO (Prevención del cáncer de cuello uterino)

1. Importe el archivo de datos de extensión xlsx.

Importaremos los datos utilizando el menú “Import Dataset” del panel *Environment*:

The image shows the RStudio Code editor with a data frame named 'sobar_72' loaded. The data frame has 17 rows and 7 columns. The columns are: behavior_sexualRisk, behavior_eating, behavior_personalHygiene, intention_aggregation, intention_commitment, attitude_consistency, and attitude_spont. The data is as follows:

	behavior_sexualRisk	behavior_eating	behavior_personalHygiene	intention_aggregation	intention_commitment	attitude_consistency	attitude_spont
1	10	13	12	4	7	9	
2	10	11	11	10	14	7	
3	10	15	3	2	14	8	
4	10	11	10	10	15	7	
5	8	11	7	8	10	7	
6	10	14	8	6	15	8	
7	10	15	4	6	14	6	
8	8	12	9	10	10	5	
9	10	15	7	2	15	6	
10	7	15	7	6	11	8	
11	7	15	7	10	14	7	
12	10	15	8	9	15	7	
13	10	15	12	10	15	6	
14	9	12	14	9	15	10	
15	2	15	15	6	13	8	
16	10	15	7	6	14	8	
17	10	15	9	7	6	8	

Antes de comenzar con el análisis de los datos, comprobaremos que la importación se ha realizado correctamente:

```
class(sobar_72); dim(sobar_72)
```

```
colnames(sobar_72); head(sobar_72)
```

```
sobar_72<-as.data.frame(sobar_72)
```

Almacenaremos los datos en un objeto de tipo matriz, que contenga las variables cuantitativas a analizar,

```
datos<-as.matrix(sobar_72 [, -20])
```

```
dim(datos); class(datos); head(datos)
```


ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

2. Calcule la matriz de correlaciones R y represéntela gráficamente.


La función `cor` calcula la matriz de correlaciones de un conjunto de datos y la función `corrplot` de la librería `corrplot` representa gráficamente la misma.

```
R<-cor(datos)
```

	behavior_sexualrisk	behavior_eating	behavior_personalHygiene	intention_aggregation	intention_commitment
behavior_sexualrisk	1.000	-0.166	0.004	-0.006	0.127
behavior_eating	-0.166	1.000	0.225	0.117	0.116
behavior_personalHygiene	0.004	0.225	1.000	0.442	0.010
intention_aggregation	-0.006	0.117	0.442	1.000	0.265
intention_commitment	0.127	0.116	0.010	0.265	1.000
attitude_consistency	-0.068	0.124	0.152	-0.040	-0.006
attitude_spontaneity	-0.057	0.308	-0.118	-0.176	0.230
norm_significantPerson	0.058	0.038	0.237	0.117	0.012
norm_fulfillment	0.159	-0.068	0.253	0.059	-0.032
perception_vulnerability	0.176	0.000	0.140	-0.045	-0.012
perception_severity	0.067	-0.077	0.252	0.062	-0.022
motivation_strength	-0.042	-0.142	0.387	0.338	0.181
motivation_willingness	0.309	-0.077	0.433	0.278	0.104
socialSupport_emotionality	0.076	-0.077	0.389	0.189	0.001
socialSupport_appreciation	0.102	-0.013	0.354	0.080	0.016
socialSupport_instrumental	0.104	0.062	0.098	0.035	0.016
empowerment_knowledge	0.174	0.060	0.444	0.267	0.146
empowerment_abilities	0.206	-0.016	0.392	0.106	0.057
empowerment_desires	0.285	0.052	0.199	0.127	0.176

```
library(corrplot)
```

```
corrplot(R, tl.col="black", tl.srt=45, tl.cex = 0.8, type="upper")
```



Se observan dos grupos de variables altamente correlacionadas

3. Centre y estandarice la matriz de datos y almacene la nueva matriz en un objeto denominado `datos.est`.

La matriz de datos centrada y estandarizada se obtiene mediante la función `scale`:

```
datos.est<-scale(datos, center=T, scale=T)
```

	behavior_sexualRisk	behavior_eating	behavior_personalHygiene	intention_aggregation	intention_commitment	attitude_consistency
[1,]	0.2808717	0.0882285	0.30214667	-1.42533462	-2.6730651	1.1947676
[2,]	0.2808717	-0.7587651	-0.02746788	0.76592714	0.2749104	-0.1185647
[3,]	0.2808717	0.9352221	-2.66438430	-2.15575520	0.2749104	0.5381014
[4,]	0.2808717	-0.7587651	-0.35708243	0.76592714	0.6960498	-0.1185647
[5,]	-1.4043583	-0.7587651	-1.34592609	0.03550656	-1.4096470	-0.1185647
[6,]	0.2808717	0.5117253	-1.01631154	-0.69491403	0.6960498	0.5381014

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

4. Calcule la Descomposición Espectral de la matriz de covarianzas de *datos.est* y la Descomposición en Valores Singulares de los datos originales. ¿Qué relación observa entre los resultados?

A continuación, obtenemos la descomposición espectral de la matriz de covarianzas:

```
eigen(cov(datos.est))
```

```
eigen() decomposition
$values
[1] 5.45462010 3.53525766 1.68079922 1.57072572 1.25173603 0.96233898
[7] 0.83381871 0.66115651 0.57132820 0.46743361 0.45657456 0.39455718
[13] 0.29604225 0.24355096 0.20260726 0.15256591 0.11295342 0.08808402
[19] 0.06384970

$vectors
      [,1]      [,2]      [,3]      [,4]      [,5]
[1,] 0.103321499 0.065606093 0.25046801 0.15014837 0.543685996
[2,] 0.001860535 -0.016547557 -0.51203841 0.19603543 -0.207443735
[3,] 0.218474477 0.179417053 -0.27839775 -0.29185523 -0.237545185
[4,] 0.127109341 0.076996576 -0.33511888 -0.48754242 0.183828747
[5,] 0.059120280 -0.002434523 -0.36344218 0.01960899 0.626015269
[6,] -0.029146632 0.161183609 -0.28988544 0.22672238 -0.262918122
[7,] -0.013585489 -0.083331315 -0.40299621 0.49720652 0.103110705
[8,] -0.018169086 0.428448507 -0.01537364 -0.03615219 -0.009827714
[9,] -0.004230616 0.491977483 0.06665895 0.07191344 0.022414050
[10,] 0.057985910 0.446174105 0.11979383 0.24574816 0.013299796
[11,] 0.057285025 0.479073552 0.07291333 0.10259430 -0.051352131
[12,] 0.194467256 0.128065448 -0.17186811 -0.31095057 0.082770370
[13,] 0.245666603 0.246337683 0.26682330 0.13784666 0.282418000
```

```
round(cor(datos.est)[1:3],3)
```

```
round(cov(datos.est)[1:3],3)
```

5. Implemente el Análisis de Componentes Principales a partir de la función *princomp* en RStudio. Responda a las siguientes cuestiones:

La función *princomp* permite obtener los resultados del Análisis de Componentes Principales de nuestro conjunto de datos:

```
pca.res<-princomp(datos.est, cor=T)
```

```
summary(pca.res)
```

- Obtenga los valores propios y el % de varianza explicada por cada componente.

Los valores propios obtenidos para cada componente principal son:

```
valores.propios<-pca.res$sdev^2
```

```
> valores.propios
  Comp.1    Comp.2    Comp.3    Comp.4    Comp.5    Comp.6
5.45462010 3.53525766 1.68079922 1.57072572 1.25173603 0.96233898
```

Y a partir de ellos calculamos el porcentaje de varianza explicada por cada componente como:

```
(valores.propios[1]/sum(valores.propios))*100
```

```
(valores.propios[2]/sum(valores.propios))*100
```

La primera componente principal explica el 28,71% de la variabilidad de los datos, y la segunda el 18.61%.


ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

- ¿Cuántas componentes principales debemos retener? Ayúdese del scree-plot y del listado de valores propios.

Para obtener el gráfico de sedimentación o *scree plot* es suficiente con:

```
plot(pca.res, type="lines", ylim=c(0,6), main = "Gráfico de sedimentación")
```



Así:

Autovalores mayores a 1: 5

Porcentaje de varianza del 75%: 6

Gráfico de sedimentación: 3

Decisión del investigador: 3

- Analice la estructura de la matriz de cargas para las componentes extraídas:

```
pca.res$loadings[,1:3]
```

	Comp.1	Comp.2	Comp.3
behavior_sexualrisk	0.103	0.066	0.250
behavior_eating	0.002	-0.017	-0.512
behavior_personalHygiene	0.218	0.179	-0.278
intention_aggregation	0.127	0.077	-0.335
intention_commitment	0.059	-0.002	-0.363
attitude_consistency	-0.029	0.161	-0.290
attitude_spontaneity	-0.014	-0.083	-0.403
norm_significantPerson	-0.018	0.428	-0.015
norm_fulfillment	-0.004	0.492	0.067
perception_vulnerability	0.058	0.446	0.120
perception_severity	0.057	0.479	0.073
motivation_strength	0.194	0.128	-0.172
motivation_willingness	0.345	0.040	0.070
socialSupport_emotionality	0.364	-0.057	0.108
socialSupport_appreciation	0.343	-0.111	0.109
socialSupport_instrumental	0.321	-0.177	0.071
empowerment_knowledge	0.367	0.005	-0.124
empowerment_abilities	0.381	0.012	0.060
empowerment_desires	0.352	-0.070	0.020

ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

Así, las primeras componentes principales vienen dadas por la combinación lineal de las variables originales estandarizadas:

$$Y_1 = 0,1 \cdot z_{SR} + 0,002 \cdot z_{Eat} + 0,2 \cdot z_{PHyg} + \dots + 0,381 \cdot z_{abi} + 0,352 \cdot z_{Des}$$

$$Y_2 = 0,066 \cdot z_{SR} - 0,017 \cdot z_{Eat} + 0,179 \cdot z_{PHyg} + \dots + 0,012 \cdot z_{abi} - 0,07 \cdot z_{Des}$$

$$Y_3 = 0,25 \cdot z_{SR} - 0,512 \cdot z_{Eat} - 0,278 \cdot z_{PHyg} + \dots + 0,060 \cdot z_{abi} + 0,020 \cdot z_{Des}$$

- Realice la representación gráfica de las puntuaciones de los individuos en el espacio generado por las dos primeras componentes principales.

Las puntuaciones de las observaciones en el espacio de componentes principales son:

```
pca.res$scores[,1:3]
```

	Comp.1	Comp.2	Comp.3
[1,]	-0.343	-0.937	0.446
[2,]	-1.530	-0.266	0.171
[3,]	-3.062	-2.570	0.483
[4,]	-1.936	-1.144	0.079
[5,]	-2.429	-2.124	0.607
[6,]	-1.427	-1.802	-1.153
[7,]	-2.812	-1.569	0.312
[8,]	-1.064	-1.220	0.202
[9,]	1.984	-3.069	0.733
[10,]	-3.450	-0.906	-0.660
[11,]	-2.000	-2.592	-0.795
[12,]	-1.642	-1.938	-1.329
[13,]	-1.582	-2.590	-1.415
[14,]	0.527	-1.042	-1.581
[15,]	-2.452	-1.730	-2.986
[16,]	-4.327	-0.248	0.152
[17,]	-3.665	-0.572	0.978
[18,]	-4.414	-0.545	1.446
[19,]	-4.079	0.380	1.639


Para obtener el gráfico de puntuaciones en el espacio de las componentes:

```
colors <- c(rep("#E69F00",21), rep("#999999",51))
```

```
plot(pca.res$scores[,1:2], pch=19, #col=as.factor(Arqueologia2$Type),
```

```
main="Espacio de puntuaciones en las Componentes Principales",col=colors)
```

```
text(pca.res$scores[,1:2]+0.1, label=cervix, cex=0.6 )
```




ANÁLISIS DE COMPONENTES PRINCIPALES EN R

Análisis Multivariante – Grado en Estadística

O incluso puede representarse en un espacio tridimensional:

```
library(scatterplot3d)  
scatterplot3d(pca.res$scores[,1:3], pch=19, angle = 60, color=colors)
```



Preguntas propuestas:

- 1- ¿Las componentes principales obtenidas son variables incorrelacionadas?
- 2- ¿Qué relación hay ahora entre la matriz de covarianzas y de correlaciones? ¿Y entre los resultados del ACP y la descomposición espectral?