



Análisis de Componentes Principales



Nerea González García



No supervisado

Técnicas de agrupamiento

Si el objetivo es encontrar agrupaciones de observaciones con patrones de comportamiento similares

Técnicas de reducción de la dimensionalidad


Si lo que se busca es representar la información en un subespacio de dimensión menor en el que sintetizar de una manera más simple las posibles relaciones existentes

Técnicas de clasificación

Si ya se dispone de una clasificación de las observaciones y el interés se centra en detectar cuales son los factores que influyen en dicha clasificación

Técnicas de regresión


Si se busca la influencia de un conjunto de variables sobre el comportamiento de otra u otras



Supervisado

Alumno	Matemáticas	Física
Ana	4	6
Juan	5	6
Lucas	6	8
Ester	7	8
Rocío	8	7
Álex	9	9
Tomás	5	3.5
Elisa	3	3

Alumno	Matemáticas	Física
Ana	4	6
Juan	5	6
Lucas	6	8
Ester	7	8
Rocío	8	7
Álex	9	9
Tomás	5	3.5
Elisa	3	3



Alumno	Matemáticas	Física	Lengua
Ana	4	6	8
Juan	5	6	7
Lucas	6	8	4
Ester	7	8	7
Rocío	8	7	6
Álex	9	9	6
Tomás	5	3.5	5
Elisa	3	3	3

Definición

El ACP es una técnica de **reducción de la dimensión** que describe la información de un conjunto de **variables observadas** mediante un menor número de nuevas variables (COMPONENTES PRINCIPALES), transformaciones ortogonales de las originales, estadísticamente incorrelacionadas, que maximicen la variabilidad original de los datos en orden decreciente de importancia.

Conceptos iniciales

Técnica de reducción de la dimensionalidad



Fuente:


Nerea González García

Análisis de Componentes Principales


**Variabilidad
es equivalente a
Información**

**ALTAS CORRELACIONES ENTRE
LAS VARIABLES IMPLICAN ÉXITO**

Low redundancy



High redundancy



x and y are "arbitrary" axes to describe the data

Reducción de la Dimensión - Máxima información

¿Por qué son importantes los ejes de máxima variabilidad?



Reducción de la Dimensión




¿Cómo hacemos la fotografía que capture la máxima información?

Reducción de la Dimensión

¿Cómo lo conseguimos?

Rotando el objeto hasta
encontrar las direcciones de
máxima variabilidad
(de acuerdo al ACP)




¿Por qué esta posición? Porque proporciona la máxima información visual

Reducción de la Dimensión




Encontrando el eje de máxima variabilidad...



Reducción de la Dimensión




Encontrando el eje de máxima variabilidad...



Conceptos iniciales



Proyección



Fuente:


Nerea González García

Análisis de Componentes Principales

Conceptos iniciales



Proyección



Fuente:


Nerea González García

Análisis de Componentes Principales

Conceptos iniciales



Centrar los datos (trasladar al centro de gravedad)



Se asumen datos centrados

Conceptos iniciales

Matriz de covarianzas

Matriz de covarianzas

La matriz de covarianzas es aquella matriz cuyo elemento ij -ésimo es:

$$s_{ij} = \text{cov}(X_i, X_j) \quad i \neq j$$

$$s_{ii} = \text{var}(X_i) \quad i = j$$

La matriz de covarianzas se calcula como:

$$S = \frac{1}{n} C$$

$$S = \frac{1}{n-1} C$$

$$S = \begin{pmatrix} s_{11}^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22}^2 & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp}^2 \end{pmatrix}$$

Herramientas matemáticas a utilizar

Matriz de correlación

Matriz de correlaciones

La matriz de correlaciones es aquella matriz cuyo elemento ij -ésimo es:

$$r_{ij} = \text{corr}(X_i, X_j) \quad i \neq j$$

$$r_{ii} = 1 \quad i = j$$

La matriz de correlaciones se calcula como:

$$R = D_S^{-1/2} S D_S^{-1/2}$$

donde D_S es la matriz diagonal que contiene las varianzas de las variables.

$$R = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

Conceptos iniciales

Matriz de covarianzas

Matriz de covarianzas

La matriz de covarianzas es aquella matriz cuyo elemento ij -ésimo es:

$$s_{ij} = \text{cov}(X_i, X_j) \quad i \neq j$$

$$s_{ii} = \text{var}(X_i) \quad i = j$$

La matriz de covarianzas se calcula como:

$$S = \frac{1}{n} C$$

$$S = \frac{1}{n-1} C$$

Herramientas matemáticas a utilizar

Matriz de correlación

Matriz de correlaciones

La matriz de correlaciones es aquella matriz cuyo elemento ij -ésimo es:

$$r_{ij} = \text{corr}(X_i, X_j) \quad i \neq j$$

$$r_{ii} = 1 \quad i = j$$

La matriz de correlaciones se calcula como:

$$R = D_S^{-1/2} S D_S^{-1/2}$$

donde D_S es la matriz diagonal que contiene las varianzas de las variables.

Descomposición espectral

La expresión $A = CDC'$ se denomina descomposición espectral de A .

Dado que C es ortogonal, se cumple $CC' = C'C = I$, por lo tanto, $C'AC = D$. Es decir, una matriz simétrica puede ser diagonalizada por una matriz ortogonal formada por sus vectores propios, conteniendo en la diagonal los valores propios de la misma.

C es una matriz que contiene los vectores propios ortogonales de una matriz simétrica A ,

Descomposición en Valores Singulares

De la misma manera que se puede expresar una matriz simétrica en función de sus valores y vectores propios, también se puede expresar cualquier matriz A en función de los valores y vectores propios de AA' y $A'A$. Si A es una matriz de dimensión $n \times p$ de rango k , la descomposición en valores singulares de A viene expresada como:

$$A = UDV'$$

Definición


El ACP es una técnica de **reducción de la dimensión** que describe la información de un conjunto de **variables observadas** mediante un **nuevo conjunto de variables** latentes **más pequeño** que maximicen la información
(conocidas como componentes principales)

El Análisis de Componentes principales consiste en encontrar transformaciones **ortogonales** de las variables originales para conseguir un nuevo conjunto de variables **incorrelacionadas**, denominadas Componentes Principales, que se obtienen en **orden decreciente de importancia**

Datos de partida


- Todas las variables tienen el mismo papel, es decir, el conjunto no se divide en variables dependientes e independientes.
- Matriz $\mathbf{X}_{n \times p}$ que contiene la medición de p variables cuantitativas sobre n observaciones (con $n > p$).

$$\mathbf{X}_{n \times p} = (x_{ij}) = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$


 $\mathbf{X}_{n \times p}$

NOTA: Supondremos, sin pérdida de generalidad, que las columnas de $\mathbf{X}$ tienen media cero, es decir, la matriz de datos **centrada** (se le ha restado la media de cada variable (columna)), de forma que el origen se sitúa en el centro de gravedad de la nube de puntos. También, que $rg(\mathbf{X}) = p$

Formulación del ACP: métodos de obtención de las CPs



Definición

Sea $\mathbf{X} = [X_1, \dots, X_p]$ una matriz de datos multivariantes, que recoge la información de n observaciones sobre las que se han medido p variables observadas ($n > p$). Supóngase que $\mathbf{X}$ es de rango completo.

Las componentes principales son variables incorrelacionadas tales que unas pocas explican la mayor parte de la variabilidad de $\mathbf{X}$.


Definición. Se definen las componentes principales $Y_1, \dots, Y_p$ como las variables:

$$Y_1 = \mathbf{X}\mathbf{v}_1; Y_2 = \mathbf{X}\mathbf{v}_2, \dots, Y_p = \mathbf{X}\mathbf{v}_p$$


tales que:

- i. La variable Y_1 es tal que $\text{var}(Y_1)$ es máxima, sujeto a $\mathbf{v}_1'\mathbf{v}_1 = 1$.
- ii. Entre todas las variables Y tales que $\text{cov}(Y_1, Y) = 0$, la variable Y_2 es tal que $\text{var}(Y_2)$ es máxima, sujeto a $\mathbf{v}_2'\mathbf{v}_2 = 1$.
- iii. Si $p \geq 3$, la componente principal Y_3 es una variable incorrelacionada con Y_1, Y_2 , de varianza máxima y unitaria.
- iv. ...

ACP bidimensional



Punto de vista de las componentes



$$\begin{matrix} (y_{i1} & y_{i2}) \\ 1 \times 2 \end{matrix} = \begin{matrix} (x_{i1} & x_{i2}) \\ 1 \times 2 \end{matrix} \begin{matrix} \begin{pmatrix} v_{11} \\ v_{21} \end{pmatrix} & \begin{pmatrix} v_{12} \\ v_{22} \end{pmatrix} \\ 2 \times 2 \end{matrix}$$



$$\begin{cases} y_{i1} = x_{i1}v_{11} + x_{i2}v_{21} \\ y_{i2} = x_{i1}v_{12} + x_{i2}v_{22} \end{cases}$$



¿Y si fueran p variables originales?

$X_1, \dots, X_p$

$$\begin{matrix} (y_{i1} & y_{i2}) \\ 1 \times 2 \end{matrix} = \begin{matrix} (x_{i1} & x_{i2} & \dots & x_{ip}) \\ 1 \times p \end{matrix} \begin{matrix} \begin{pmatrix} v_{11} \\ v_{21} \\ \vdots \\ v_{p1} \end{pmatrix} & \begin{pmatrix} v_{12} \\ v_{22} \\ \vdots \\ v_{p2} \end{pmatrix} \\ p \times 2 \end{matrix}$$




$$\begin{cases} y_{i1} = x_{i1}v_{11} + x_{i2}v_{21} + \dots + x_{ip}v_{p1} \\ y_{i2} = x_{i1}v_{12} + x_{i2}v_{22} + \dots + x_{ip}v_{p2} \end{cases}$$



La coordenada del individuo i en la componente j es

$$y_{ij} = x_{i1}v_{1j} + x_{i2}v_{2j} + \dots + x_{ip}v_{pj}$$



En general

$$y_{ij} = v_{1j}x_{i1} + v_{2j}x_{i2} + \cdots + v_{pj}x_{ip}$$

Para todas las observaciones
y cada una componente j -ésima:

$$Y_j = v_{1j}X_1 + v_{2j}X_2 + \cdots + v_{pj}X_p$$

$$\begin{pmatrix} y_{1j} \\ \vdots \\ y_{nj} \end{pmatrix}_{n \times 1} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}_{n \times p} \begin{pmatrix} v_{1j} \\ \vdots \\ v_{pj} \end{pmatrix}_{p \times 1}$$

Para cada componente principal se verifica:

$$Y_j = Xv_j$$
$$j = 1, \dots, ?$$



DEF: Se denominan **componentes principales**, Y_j , a las variables que se expresan como combinaciones lineales de las variables originales, conservando la máxima varianza contenida en estas y que además son incorrelacionadas entre sí.

Para todo el conjunto de datos

$$\begin{pmatrix} \mathbf{y}_1 & \dots & \mathbf{y}_J \\ y_{11} & \dots & y_{1J} \\ \dots & \dots & \dots \\ y_{n1} & \dots & y_{nJ} \end{pmatrix}_{n \times J} = \begin{pmatrix} x_{11} & \dots & x_{1p} \\ \dots & \dots & \dots \\ x_{n1} & \dots & x_{np} \end{pmatrix}_{n \times p} \begin{pmatrix} \mathbf{v}_1 & \dots & \mathbf{v}_J \\ v_{11} & \dots & v_{1J} \\ \dots & \dots & \dots \\ v_{p1} & \dots & v_{pJ} \end{pmatrix}_{p \times J}$$

En notación matricial

$$\mathbf{Y} = \mathbf{XV}$$

$$\boxed{\mathbf{Y}_{n \times J}} = \boxed{\mathbf{X}_{n \times p}} \boxed{\mathbf{V}_{p \times J}}$$

Donde **Y** contiene las puntuaciones de cada individuo sobre cada componente, y **V** contiene los coeficientes (pesos, cargas) de las combinaciones lineales en columnas.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

Buscamos una primera componente principal Y_1 que tenga varianza máxima.

(1) Como las variables originales tienen media 0, también Y_1 tendrá media nula.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

Buscamos una primera componente principal Y_1 que tenga varianza máxima.

(2) La varianza de Y_1 se calcula como:

$$Var(Y_1) = \frac{1}{n-1} Y_1^t Y_1 = \frac{1}{n-1} v_1^t X^t X v_1 = v_1^t S v_1$$

$$Y_1 = X v_1$$

$$S = \frac{1}{n-1} X^t X$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

Podemos maximizar la varianza sin límite, aumentando el módulo del vector $\mathbf{v}_1$. Es decir, en las ecuaciones de las componentes existe un factor de escala arbitraria (existen infinitas soluciones en las mismas direcciones del espacio). Para que la maximización de la varianza de Y_1 tenga solución debemos imponer una restricción. Conviene que los vectores directores tengan módulo 1:

$$\|\mathbf{v}_1\| = 1 \Rightarrow \mathbf{v}_1^t \mathbf{v}_1 = 1$$

Es decir, tomamos un vector unitario en la dirección de la primera componente principal.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

$$Var(\mathbf{y}_1) = \mathbf{v}_1^t \mathbf{S} \mathbf{v}_1$$

Se trata de buscar el máximo de

$$Var(Y_1) = \mathbf{v}_1^t \mathbf{S} \mathbf{v}_1$$

Sujeto a la restricción

$$\mathbf{v}_1^t \mathbf{v}_1 = 1$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

Se trata de buscar el máximo de

$$Var(Y_1) = \mathbf{v}_1^t \mathbf{S} \mathbf{v}_1$$

Sujeto a la restricción

$$\mathbf{v}_1^t \mathbf{v}_1 = 1$$

Introduciendo el multiplicador de Lagrange, se trata de buscar el máximo de

$$L(\mathbf{v}_1) = \mathbf{v}_1' \mathbf{S} \mathbf{v}_1 - \lambda(\mathbf{v}_1' \mathbf{v}_1 - 1)$$

Derivando e igualando a cero

$$\frac{L(\mathbf{v}_1)}{\partial \mathbf{v}_1} = 2\mathbf{S}\mathbf{v}_1 - 2\lambda\mathbf{v}_1 = 0 \quad \longrightarrow \quad \boxed{\mathbf{S}\mathbf{v}_1 = \lambda\mathbf{v}_1}$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

$$S\mathbf{v}_1 = \lambda \mathbf{v}_1$$

DESCOMPOSICIÓN ESPECTRAL
VALORES Y VECTORES PROPIOS

Definición

Para cada matriz cuadrada A existe un escalar λ y un vector no nulo x tal que:

$$Ax = \lambda x$$

λ se denomina valor propio de A y x vector propio de A correspondiente a λ .

Para encontrar estos valores se tiene que resolver la siguiente ecuación:

$$(A - \lambda I)x = 0$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

$$\mathbf{S}\mathbf{v}_1 = \lambda\mathbf{v}_1$$

Esto quiere decir que $\mathbf{v}_1$ debe ser un vector propio de la matriz de covarianzas $\mathbf{S}$ con valor propio asociado λ .

...pero $\mathbf{S}$ tiene p valores propios $\lambda_1, \dots, \lambda_p$ que supondremos distintos y ordenados en orden decreciente $\lambda_1 \geq \dots \geq \lambda_p \geq 0$.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la primera CP

$$\mathbf{S}\mathbf{v}_1 = \lambda\mathbf{v}_1$$

Esto quiere decir que $\mathbf{v}_1$ debe ser un vector propio de la matriz de covarianzas $\mathbf{S}$ con valor propio asociado λ .

Teniendo en cuenta que

- $Var(\mathbf{y}_1) = Var(\mathbf{X}\mathbf{v}_1) = \mathbf{v}_1^t \mathbf{S} \mathbf{v}_1 = \mathbf{v}_1^t \lambda \mathbf{v}_1 = \lambda \mathbf{v}_1^t \mathbf{v}_1 = \lambda$
- Las componentes principales maximizan la variabilidad (la PC1 es la que más varianza explica, seguido de la PC2, y así secuencialmente...

λ debe ser λ_1 el valor propio más grande y $\mathbf{v}_1$ el vector propio asociado, por lo que el primer valor propio se puede interpretar como la varianza muestral de la primera componente principal.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la segunda CP

La segunda componente principal $\mathbf{y}_2 = \mathbf{X}\mathbf{v}_2$, se obtiene de forma similar, pero añadiendo la restricción adicional de que Y_1 e Y_2 sean incorreladas, como habíamos establecido en la definición de las componentes:

$$\text{Cov}(Y_1, Y_2) = \frac{1}{n-1} \mathbf{y}_2' \mathbf{y}_1 = \frac{1}{n-1} \mathbf{v}_2' \mathbf{X}' \mathbf{X} \mathbf{v}_1 = \mathbf{v}_2' \mathbf{S} \mathbf{v}_1 = \mathbf{v}_2' \lambda_1 \mathbf{v}_1 = 0$$



$$\mathbf{v}_2' \mathbf{v}_1 = 0$$

Utilizando multiplicadores para ambas restricciones, se trata de buscar el máximo de

$$L(\mathbf{v}_2) = \mathbf{v}_2' \mathbf{S} \mathbf{v}_2 - \lambda(\mathbf{v}_2' \mathbf{v}_2 - 1) - \delta \mathbf{v}_2' \mathbf{v}_1$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la segunda CP

Derivando e igualando a cero

$$\frac{L(\mathbf{v}_2)}{\partial \mathbf{v}_2} = 2\mathbf{S}\mathbf{v}_2 - 2\lambda\mathbf{v}_2 - \delta\mathbf{v}_1 = 0$$

premultiplicando por $\mathbf{v}_1'$,

$$2\mathbf{v}_1'\mathbf{S}\mathbf{v}_2 - 2\lambda\mathbf{v}_1'\mathbf{v}_2 - \delta\mathbf{v}_1'\mathbf{v}_1 = 0$$

$$2\mathbf{v}_1'\mathbf{S}\mathbf{v}_2 - \delta = 0$$

como ,

$$\mathbf{v}_1'\mathbf{S}\mathbf{v}_2 = 0 \longrightarrow \text{Entonces } \delta = 0 \text{ en el punto estacionario}$$

De forma que:

$$\longrightarrow 2\mathbf{S}\mathbf{v}_2 - 2\lambda\mathbf{v}_2 = 0 \longrightarrow \boxed{\mathbf{S}\mathbf{v}_2 = \lambda\mathbf{v}_2}$$

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

Búsqueda de la segunda CP

$$\mathbf{S}\mathbf{v}_2 = \lambda \mathbf{v}_2$$


con lo que λ es el segundo valor propio λ_2 y $\mathbf{v}_2$ es el segundo vector propio.

Siguiendo con el mismo argumento, podemos obtener las sucesivas componentes principales a partir de los correspondientes valores y vectores propios.

Obtención de las Componentes Principales (CPs) mediante la maximización de la variabilidad

En definitiva, las componentes principales se obtienen de la descomposición en valores propios (autovalores) y vectores propios (autovectores) de la matriz de covarianzas (varianzas-covarianzas)

$$\mathbf{S} = \mathbf{V}'\mathbf{\Lambda}\mathbf{V} \quad \begin{cases} \mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p) \\ \mathbf{V}'\mathbf{V} = \mathbf{I} \end{cases}$$



$$\mathbf{S} \quad \mathbf{\Lambda} \quad \mathbf{V}$$

El poder de la Descomposición Espectral

Valores y vectores propios

Teorema Espectral: Sea A matriz $\in \mathbb{R}^{p \times p}$, simétrica y semidefinida positiva. Existe una factorización de A de la forma:

$$A = V\Lambda V^T$$

Donde:


- $\Lambda \in \mathbb{R}^{p \times p}$ es una matriz diagonal cuyos elementos se corresponden con los valores propios $\lambda_i \geq 0$ $i = 1, \dots, p$ de la matriz A .
- $V \in \mathbb{R}^{p \times p}$ es una matriz cuadrada ortogonal cuyas columnas contienen los vectores propios normalizados de la matriz A asociados a los valores propios Λ .



El poder de la Descomposición Espectral y la matriz de Varianzas-Covarianzas

Valores propios
no negativos

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, p$$



Vectores propios
ortogonales
dos a dos

$$\mathbf{v}_i^T \mathbf{v}_j = 0 \quad \forall i \neq j$$


$$\mathbf{S}_{p \times p} = \mathbf{V}_{p \times p} \mathbf{\Lambda}_{p \times p} \mathbf{V}_{p \times p}^T$$

Definición

(Cuadras, 2014)

Si $V = [v_1, \dots, v_p]$ es la matriz de dimensión $p \times p$ cuyas columnas son los vectores que definen las componentes principales, entonces las puntuaciones de las n observaciones en las componentes principales vienen dadas por la transformación lineal:


$$Y = XV$$


$$Y_{n \times p} = X_{n \times p} V_{p \times p}$$

Para todas las observaciones y cada componente j -ésima:

$$Y_j = v_{1j}X_1 + v_{2j}X_2 + \dots + v_{pj}X_p$$


$$Y = XV$$


$$Y_{n \times J} = X_{n \times p} V_{p \times J}$$


Donde **Y** contiene las puntuaciones de cada individuo sobre cada componente, y **V** contiene los coeficientes (pesos) de las combinaciones lineales en columnas.

Reducción de la dimensión

$$Y = XV$$

Hay tantas componentes principales, como rango r de la matriz X (¿variables de partida en la matriz X ($J = p$)?)

Seleccionando $q, q < r$, componentes, las puntuaciones de los individuos en las componentes principales están dadas por

$$Y_q = XV_q$$


donde V_q está formada por las q primeras columnas de V (contribución de las p variables originales en q componentes principales)






Original



CPs=400



CPs=5

Original



CPs=400




CPs=300



CPs=200



CPs=100



CPs=50



Original



Image Compression

Components	Size (Kilobyte)	Size Original (Kilobyte)	%Diff
5	43.873	147.587	-70%
50	85.589	147.587	-42%
100	99.62	147.587	-33%
150	105.042	147.587	-29%
200	106.781	147.587	-28%
250	106.171	147.587	-28%

Original



Image Compression

Components	Size (Kilobyte)	Size Original (Kilobyte)	%Diff
5	43.873	147.587	-70%
50	85.589	147.587	-42%
100	99.62	147.587	-33%
150	105.042	147.587	-29%
200	106.781	147.587	-28%
250	106.171	147.587	-28%

Solución ACP


Las componentes principales se obtienen de la descomposición en valores y vectores propios de la matriz de covarianzas.

The diagram illustrates the Principal Component Analysis (PCA) decomposition. It shows a large square box on the left labeled $S_{p \times p}$, followed by an equals sign. To the right of the equals sign are three square boxes. The first box is labeled $V_{p \times p}$. The second box contains a diagonal matrix $\Lambda_{p \times p}$, represented by a series of squares of decreasing size along the main diagonal. The third box is labeled $V_{p \times p}^T$.


$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

$$V^T V = I_p$$


Proceso ACP




¿Dónde queda la reducción de la dimensión?




$$q < p$$



Puedo reducir la dimensión, pero... ¿dónde paro? Bondad de ajuste



Puedo reducir la dimensión, pero... ¿dónde paro? Bondad de ajuste



Proposición. Las componentes principales $Y_1, \dots, Y_p$ poseen propiedades en términos de variabilidad:

- i) La varianza de cada CP es igual al correspondiente vector propio asociado al

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, p$$

$$\text{Var}(Y_q) = \lambda_j \quad \forall q \in \{1, \dots, p\}$$

- ii) La varianza total explicada por las CPs coincide con la varianza total a explicar del conjunto de datos.

- iii) El porcentaje de variabilidad explicado por las primeras k componentes Y_k viene dado por:

$$\frac{\sum_{q=1}^k \lambda_q}{\sum_{q=1}^p \lambda_q} \cdot 100\%$$

PASOS DEL ACP

1. CENTRAR LA MATRIZ DE DATOS.

¿Estandarizar la matriz de datos?

2. CALCULAR LA MATRIZ DE COVARIANZAS.

3. DESCOMPOSICIÓN ESPECTRAL DE LA MATRIZ DE COVARIANZAS.

4. PROYECCIÓN DE LOS DATOS EN EL ESPACIO DE COMPONENTES.

5. INTERPRETACIÓN DE RESULTADOS.

- Varianza explicada ($\lambda_1, \dots, \lambda_J$)
- Matriz de cargas (V)
- Matriz de puntuaciones factoriales (Y)

PASOS DEL ACP

1. CENTRAR LA MATRIZ DE DATOS.
¿Estandarizar la matriz de datos?
2. CALCULAR LA MATRIZ DE COVARIANZAS.
3. DESCOMPOSICIÓN ESPECTRAL DE LA MATRIZ DE COVARIANZAS.
4. PROYECCIÓN DE LOS DATOS EN EL ESPACIO DE COMPONENTES.
5. INTERPRETACIÓN DE RESULTADOS.
 - Varianza explicada ($\lambda_1, \dots, \lambda_r$)
 - Matriz de cargas (V)
 - Matriz de puntuaciones factoriales (Y)

PASOS DEL ACP

1. CENTRAR LA MATRIZ DE DATOS.
¿Estandarizar la matriz de datos?
2. CALCULAR LA MATRIZ DE COVARIANZAS.
3. DESCOMPOSICIÓN ESPECTRAL DE LA MATRIZ DE COVARIANZAS.
4. PROYECCIÓN DE LOS DATOS EN EL ESPACIO DE COMPONENTES.
5. INTERPRETACIÓN DE RESULTADOS.
 - Varianza explicada ($\lambda_1, \dots, \lambda_r$)
 - Matriz de cargas (V)
 - Matriz de puntuaciones factoriales (Y)

Bondad de ajuste

**PROPORCIÓN DE VARIANZA ABSORBIDA
POR CADA COMPONENTE**

$$\frac{\lambda_j}{\sum_{j=1}^p \lambda_j} \times 100$$

**BONDAD DEL AJUSTE
(q COMPONENTES)**

$$\frac{\sum_{j=1}^q \lambda_j}{\sum_{i=1}^p \lambda_i} \times 100$$

Ejemplo inicial: Asignaturas

$n=15$ estudiantes

$p=7$ variables

$X_{15 \times 7}$



X_1 =Lengua

X_2 =Matemáticas

X_3 =Física

X_4 =Filosofía

X_5 =Historia

X_6 =Química

X_7 =Educación física

Alumno	Lengua	Matemáticas	Física	Filosofía	Historia	Química	Educación física
1	5	5	5	5	5	5	5
2	7	4	3	4	7	3	8
3	5	8	7	5	6	7	5
4	7	2	4	7	7	3	6
5	8	9	10	8	7	9	4
6	4	9	8	3	4	7	5
7	6	4	4	5	5	3	7
8	4	7	8	3	2	8	3
9	5	5	4	6	5	5	1
10	7	4	5	8	8	4	6
...	...	...	...	...	...	...	...
15	5	6	6	5	5	6	6

Ejemplo inicial: Asignaturas

Los **valores propios** (λ_j) representan la varianza de las nuevas variables; es decir, su capacidad informativa

	Valores propios	Varianza explicada (%)	Varianza acumulada (%)
	λ_i	$(\lambda_i / \sum_{i=1}^7 \lambda_i) \times 100 (\%)$	
Comp.1	12.692	49.254	49.254
Comp.2	8.266	32.079	81.333
Comp.3	3.519	13.657	94.991
Comp.4	0.564	2.189	97.180
Comp.5	0.350	1.360	98.539
Comp.6	0.257	0.999	99.538
Comp.7	0.119	0.462	100.00
Total		100	-

Ejemplo inicial: Asignaturas

Los **valores propios** (λ_j) representan la varianza de las nuevas variables; es decir, su capacidad informativa

	Valores propios	Varianza explicada (%)	Varianza acumulada (%)
	λ_i	$(\lambda_i / \sum_{i=1}^7 \lambda_i) \times 100 (\%)$	
Comp.1	12.692	49.254	49.254
Comp.2	8.266	32.079	81.333
Comp.3	3.519	13.657	94.991
Comp.4	0.564	2.189	97.180
Comp.5	0.350	1.360	98.539
Comp.6	0.257	0.999	99.538
Comp.7	0.119	0.462	100.00
Total		100	-

El resto aporta muy poca información

Interpretación de resultados: Bondad de ajuste


¿Cuántas componentes debemos retener?

- **Valores propios mayores que 1:** Se seleccionan tantos ejes como valores propios mayores que uno haya.
- **Scree Plot:** Gráfico de los valores propios. Se seleccionan ejes hasta que se vea un decrecimiento brusco en la magnitud de los valores propios.
- Seleccionar las componentes necesarias para explicar un determinado **porcentaje de la varianza**.
- Número elegido a **priori** por el usuario

Interpretación de resultados: Bondad de ajuste

MÉTODOS PARA DETERMINAR EL N° ÓPTIMO DE COMPONENTES A RETENER

Regla del codo - Scree Plot (Cattell,1966): representar gráficamente los valores propios en orden descendente y dibujar una recta a través de los factores con los valores propios más bajos. Se retienen los ejes que se corresponden con los autovalores que quedan por encima de la línea.



Interpretación de resultados: significado de las componentes principales

Se analizan las cargas (en valor absoluto). Aquellas variables que presentan altos coeficientes son las que tiene mayor importancia en la interpretación del eje.

Caso más interesante: las que presentan altas cargas para una componente y bajas para el resto

Ejemplo inicial: Asignaturas

La **matriz de cargas** (v_j) contiene el peso o contribución de las variables originales en la obtención de las componentes principales; es decir, su significado

	Comp.1	Comp.2
Lengua	0,019	0,477
Historia	0,041	0,600
Educación física	0,095	0,246
Filosofía	-0,013	0,587
Matemáticas	-0,576	-0,026
Física	-0,562	0,067
Química	-0,583	0,046

$$Y_1 = 0,019Len + 0,041Hist + 0,095EF - 0,013Fil - 0,576Mates - 0,562Fca - 0,583Qca$$

$$Y_2 = 0,477Len + 0,6Hist + 0,246EF + 0,587Fil - 0,026Mates + 0,067Fca + 0,046Qca$$

Ejemplo inicial: Asignaturas

La **matriz de cargas (v_j)** contiene el peso o contribución de las variables originales en la obtención de las componentes principales; es decir, su significado

	Comp.1	Comp.2
Lengua	0,019	0,477
Historia	0,041	0,600
Educación física	0,095	0,246
Filosofía	-0,013	0,587
Matemáticas	-0,576	-0,026
Física	-0,562	0,067
Química	-0,583	0,046

Interpretación de las componentes

1ª CP: **CIENCIAS**

2ª CP: **LETRAS**



	Ciencias	Letras
Lengua	0,019	0,477
Historia	0,041	0,600
Educación física	0,095	0,246
Filosofía	-0,013	0,587
Matemáticas	-0,576	-0,026
Física	-0,562	0,067
Química	-0,583	0,046

Interpretación de resultados: significado de las componentes principales

Correlaciones con las componentes

A los vectores escalados de la forma:

$$\mathbf{v}_j^* = \lambda_j^{1/2} \mathbf{v}_j$$

$$\mathbf{C} = \mathbf{V}\mathbf{\Lambda}^{1/2}$$

se les denomina factores de carga (**C**)

Cuando las componentes principales se calculan usando la matriz de correlaciones, la matriz **C** contiene las correlaciones entre las variables originales y las componentes.

A las correlaciones al cuadrado se las denomina contribuciones relativas del factor al elemento y miden la proporción de la variabilidad de las variables explicadas por cada componente.

Interpretación de resultados: puntuaciones de individuos

- **Diagramas de dispersión** que representan los valores de los individuos en las primeras componentes principales.
- Interpretación de **distancias** en términos de similitud.
- Búsqueda de **clusters** (grupos) y patrones.
- **Interpretación de las componentes utilizando las correlaciones con las variables originales.** Las posiciones de los individuos se interpretan después en relación a la interpretación dada a las componentes.


Ejemplo inicial: Asignaturas

La **matriz de puntuaciones** (Y_j) contiene las puntuaciones de los individuos en el espacio de componentes principales:

	Comp.1 Ciencias	Comp.2 Letras
Ana	0,667	-0,773
Juan	3,950	1,333
Manuel	-3,313	-0,026
Sara	4,314	2,722
Paloma	-6,779	3,785
Víctor	-4,527	-2,837
Jorge	3,181	0,065
Susana	-4,228	-4,431
María	0,838	-1,237
Javier	2,043	3,969
Mónica	-3,485	3,154
Lucía	5,069	-4,734
Pablo	2,470	3,056
Tomás	0,763	-3,608
Pilar	-0,961	-0,440


Ejemplo inicial: Asignaturas

La **matriz de puntuaciones (Y_j)** contiene las puntuaciones de los individuos en el espacio de componentes principales:



Ejemplo inicial: Asignaturas

La **matriz de puntuaciones (Y_j)** contiene las puntuaciones de los individuos en el espacio de componentes principales:




Escalas de medida

Si las escalas de medida de las variables son muy diferentes, la variabilidad estaría dominada por las variables con magnitudes mayores de forma que las primeras componentes pueden mostrar simplemente las diferencias en la escala. En este caso conviene tomar la matriz **X estandarizada** por columnas y centrando y dividiendo por la desviación típica.

En este caso las componentes estarían calculadas sobre la matriz de correlaciones.

Formulación del ACP: otros métodos de obtención de las CPs



Algunas propiedades

- Las nuevas variables (componentes principales) son incorrelacionadas, y se obtienen en orden decreciente de importancia.
- Esperamos que sólo unas pocas recojan la mayor parte de la información de los datos.
- El espacio generado por las primeras q componentes es un subespacio vectorial del espacio p -dimensional original.